



# Aprendizaje Automático Profundo (Deep Learning)

---

**Dr. Facundo Quiroga - Dr. Franco Ronchetti**



# Introducción a la Optimización de Funciones

---

# Entrenamiento = Aprendizaje = Optimización

- Aprendizaje Supervisado
  - Función de error **E**
  - Ejemplos con:
    - Valores de entrada  $\mathbf{x}_i$
    - Valores de salida  $\mathbf{y}_i$
  - Buscar **parámetros óptimos** en base a **ejemplos** y **E**

Ejemplos

Entrada	Salida
2	1
5	3.2
7	4.5
9	6

**Aprendizaje =  
Optimización** de **E**




Modelo

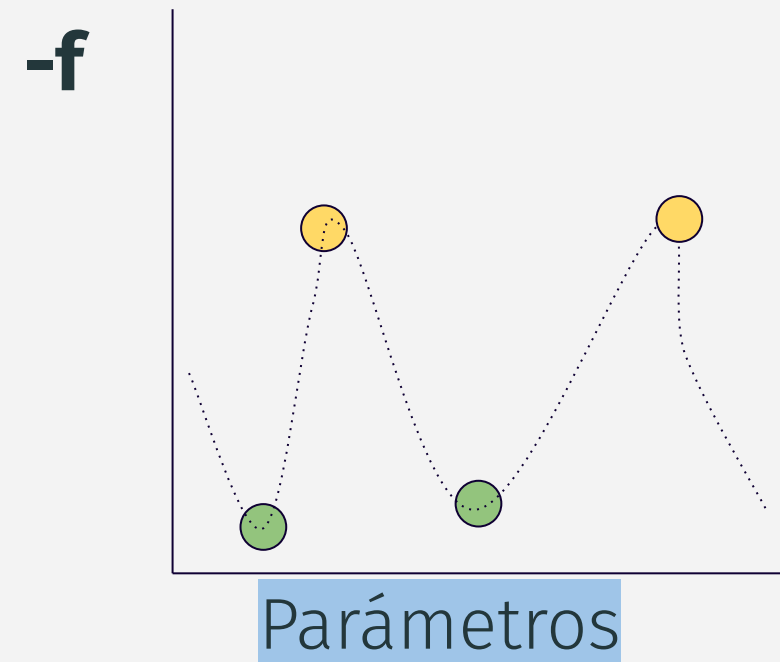
*Parámetros  
óptimos*

# Optimización de funciones

- ¿Qué significa **optimizar** una función **f**?
  - Buscar **algún** mínimo
  - Variando sus parámetros



- ¿Por qué *minimizar*?
  - *Maximizar* **f** es equivalente a *minimizar* **-f**
  - Puedo buscar máximos de **f** en los mínimos de **-f**






# Clasificación de funciones por convexidad


- Función **convexa**

- **Único** mínimo (global)
- **E** para **regresión lineal** siempre es convexa :)



- Función **no-convexa**

- **Varios** mínimos
  - Global (medio)
  - Local (otros dos)
- **E** para **redes** es no-convexa :(



# Dificultades principales


- Más de 2 parámetros (99.9% de los problemas)
  - No se puede visualizar!
    - **Algoritmos de Optimización**




# Tipos de Algoritmos de Optimización

- Generales
  - Pocas asunciones sobre **f**
  - Mayor tiempo de ejecución
  - Pocas garantías
  - Ejemplos
    - Fuerza bruta
    - Búsqueda aleatoria
- Especializados
  - Básicamente, todo lo contrario
  - **Pero no siempre existen/son aplicables**
  - Ejemplo
    - Camino mínimo en un grafo

**f**




Parámetros

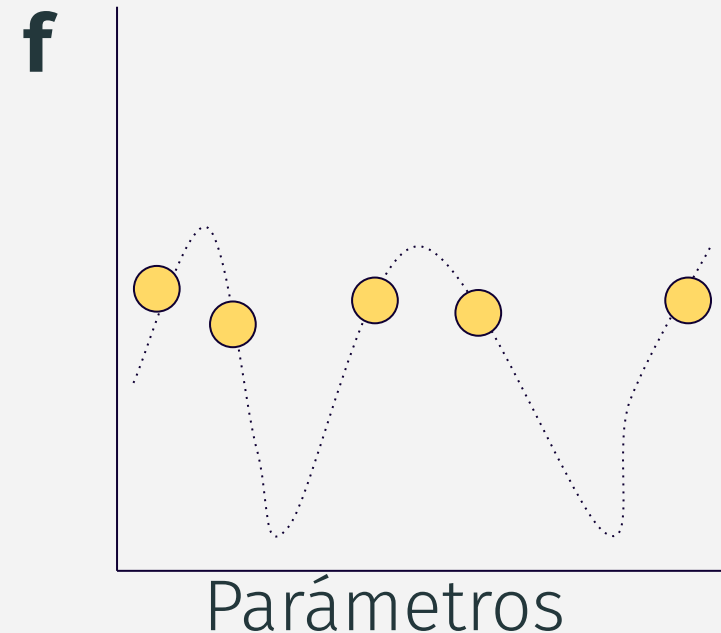


# Algoritmos generales **básicos** de optimización

- Fuerza bruta
  - Probar “todos” los valores
  - Quedarse con el mejor
    - ¿Parámetros continuos?
    - ¿Muchos parámetros?




- Búsqueda aleatoria
  - Evaluar valores aleatorios
  - Quedarse con el mejor
    - ¿Cómo generar valores aleatorios?






# Dificultades principales

- Coste computacional de evaluar la función de error
- Criterio de convergencia
  - Convergencia = terminar
  - Explotación vs exploración
    - 4 evaluaciones
      - ¿continuar o parar?
  - Varios mínimos




# Algoritmos de Optimización Especializados

- Ejemplo: buscar el camino más corto en un grafo
  - Datos: son el grafo **G**
  - Parámetros: el camino **C** a tomar
  - Función de error: Longitud camino **L(C)**
    - Encontrar camino **C**  $\in$  **G**
      - Con el menor valor de **L(C)**
  - Solución **única**
  - *Varios* algoritmos **especializados**
    - Dijkstra
    - Bellman-Ford
    - etc..




# Descenso de Gradiente (DG)

- Algoritmo general
  - Asunción: **f** es **derivable**
    - Puede tener puntos de discontinuidad
  - Utilizar el **gradiente** o **derivada** para guiar la optimización
    - **Gradiente** en un punto
    - **Dirección** de crecimiento de la función
  - Problemas
    - Mínimos locales
  - Escalable a  $n > \text{millones}$



# Descenso de gradiente (DG) : idea básica

- Empezar en un **valor aleatorio** del parámetro
  - Iterar hasta que derivada=0
    - Calcular **gradiente** o **derivada**
      - Indica dirección de maximización
    - Moverse en dirección opuesta
- Valor final: mínimo local (posiblemente global)



# Resumen

- ¿Qué significa **optimizar** una función **f**?
  - Buscar **algún** mínimo
  - Variando sus parámetros
- Algoritmos de Optimización
  - Analíticos vs Iterativos
  - Generales vs Especializados
  - Criterios de convergencia
  - Coste computacional
- Descenso de gradiente
  - Más utilizado para Redes Neuronales

