



Aprendizaje Automático Profundo (Deep Learning)


Dr. Facundo Quiroga - Dr. Franco Ronchetti



Capa GlobalAveragePooling

Global Average Pooling

- GlobalAveragePooling
 - Motivación
 - Los feature maps se achican espacialmente
 - Pero crecen en cantidad (#canales)
 - Cada canal detecta una característica
 - La dimensión espacial del feature map deja de importar
 - Método: promediar dimensiones espaciales



Global Average Pooling

- GlobalAveragePooling
 - Permite calcular puntajes para cada clase
 - Reemplaza las Dense/Flatten
- Promedia las dimensiones espaciales
 - Deja solo la dimensión de canales de un feature map
- Primero se suele utilizar una conv 1x1
 - Tantos feature maps como clases
- Ejemplo si tengo 10 clases:
 - Convolución (1x1) con 10 feature maps de HxW
 - $H \times W \times 10 = 8 \times 8 \times 64$, entonces la salida de GAP es de 10 elementos

```
model.add(Conv2D(classes,(1,1),activation="relu"))  
model.add(GlobalAveragePooling2D())  
model.add(Activation('softmax'))
```

```
def GlobalAveragePooling2D(x):  
    h,w,c=x.shape  
    y=np.zeros(c)  
    for i in range(c):  
        y[i]=x[:, :, i].mean  
    return y
```

Global Average Pooling

- GlobalAveragePooling
 - Motivación
 - El entrenar de la red, fija la resolución $H \times W$ de la imagen de entrada
 - Sucesivas capas con $\text{stride} > 1$ achican $H \times W$ a $H' \times W'$
 - La capa GlobalAveragePooling borra las dims $H' \times W'$
 - No importa la resolución original $H \times W$
 - \Rightarrow Redes independientes de la resolución de entrenamiento

