Virtualización

Que es virtualizar?

- Es una técnica que permite realizar “abstracción” de recursos de la computadora. Hoy en día también se virtualizan las redes, datacenters, etc…
- Es una capa abstracta que desacopla el hardware físico del Sistema.
- Permite ocultar detalles técnicos a través de la encapsulación
- Permite, entre otras cosas, que una computadora pueda realizar el trabajo de varias a través de la compartición de recursos de un único dispositivo de hardware

¿Que es virtualizar?

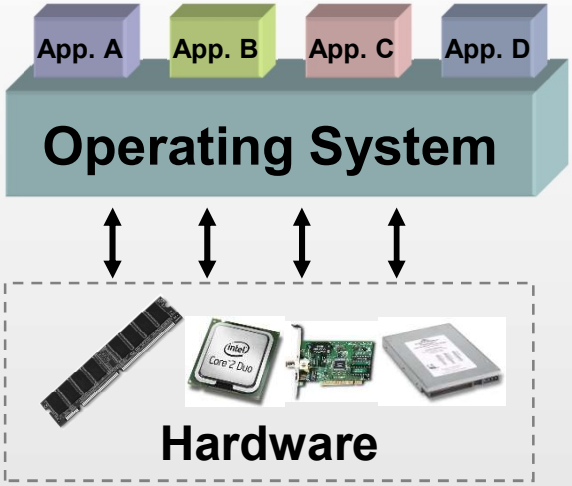

Sistema Operativo ***No Virtualizado***: un único SO controla todos los recursos de hardware

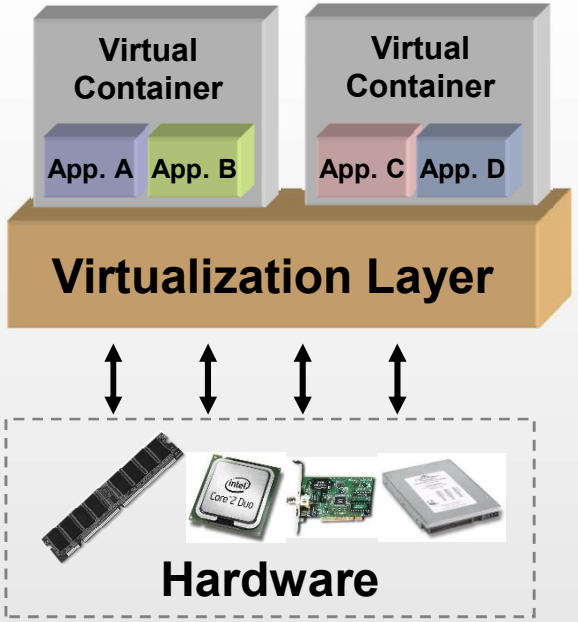

Sistema Operativo ***Virtualizado***: permite la ejecución de varios contenedores virtuales sobre el mismo hardware

Ejemplo: CMS y VM/370

- VM/CMS es un sistema operativo orientado a máquinas virtuales que se lanzó en el año 1972 por IBM
- El SO corría en entornos Mainframe con arquitectura System/370, System/390 y mas avanzados en zSeries
- Utiliza como núcleo a VMCP (Virtual Machine control program), lo que permite la ejecución de las VM y el control del hardware

<table>
<tr><td>App</td><td>App</td><td>App</td><td rowspan="2">Modo usuario</td></tr>
<tr><td>CMS</td><td>CMS</td><td>CMS</td></tr>
<tr><td colspan="3">VM/370 (VMM, Virtual Machine Monitor)</td><td>Modo protegido</td></tr>
<tr><td colspan="3">Hardware 370</td><td></td></tr>
</table>

¿Cómo trabaja CMS y VM/370?

- En VM/370, hay una máquina CMS (Conversational Monitor System) para cada usuario, con “la ilusión” del hw completo.
- Una aplicación sobre CMS hace una system call, y la “atrapa” (es un trap) CMS.
- Ejemplo: CMS emite instrucciones de I/O que son traps a VM/370

El esquema antes de la virtualización

- En el esquema de los años 2000, 1 máquina corría 1 SO junto con sus aplicaciones
- El aprovechamiento del hardware era bajo

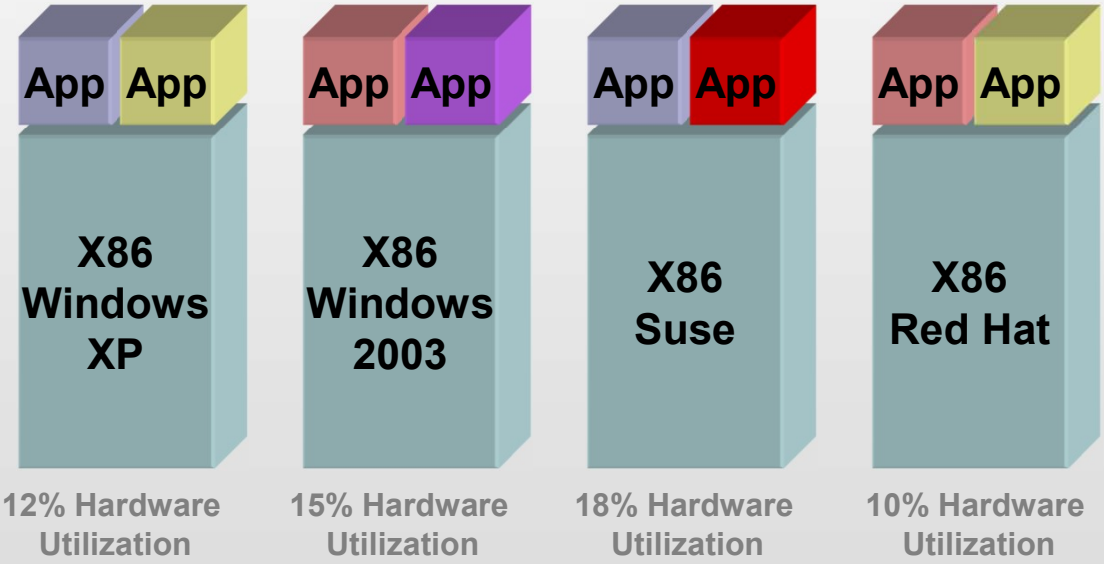

El esquema con la virtualización

- Se aprovecha el hardware, corriendo varios SO al mismo tiempo junto con sus aplicaciones
- Cada SO, desconoce de la existencia de otros SO

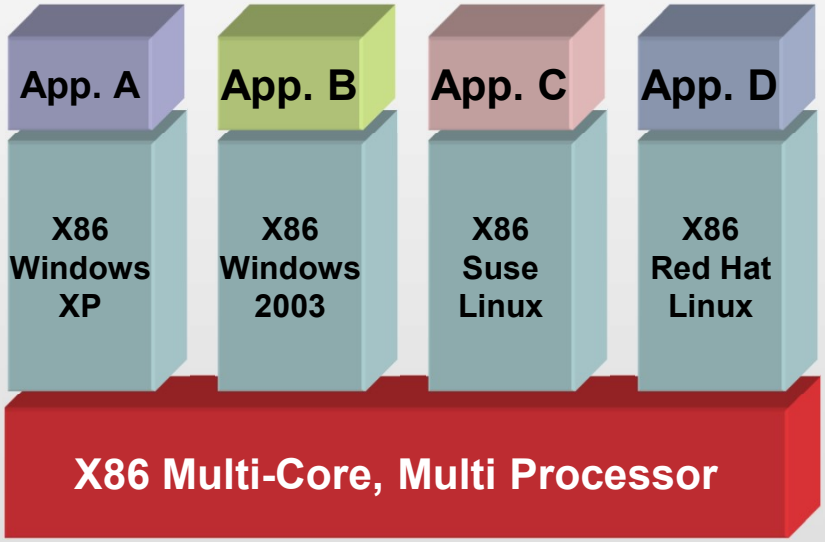

70% Hardware Utilization

¿Por qué Virtualizar?

- Tengo muchas máquinas servidores, poco usados.
- Tengo que correr aplicaciones heredadas (legacy) que no pueden ejecutarse en nuevo hw o SO.
- Tengo que probar aplicaciones no seguras.
- Tengo que crear un SO, o entornos de ejecución con recursos limitados.
- Tengo que simular la computadora real, pero con un subconjunto de recursos
- Necesito usar un hw que no tengo (necesito “crear la ilusión” de hw).
- Necesito simular redes de computadoras independientes.

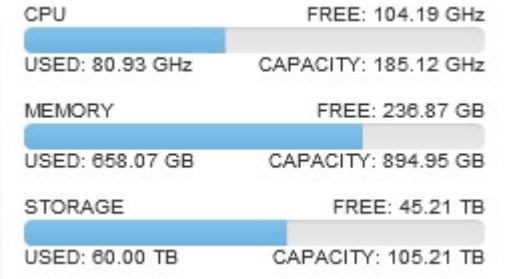

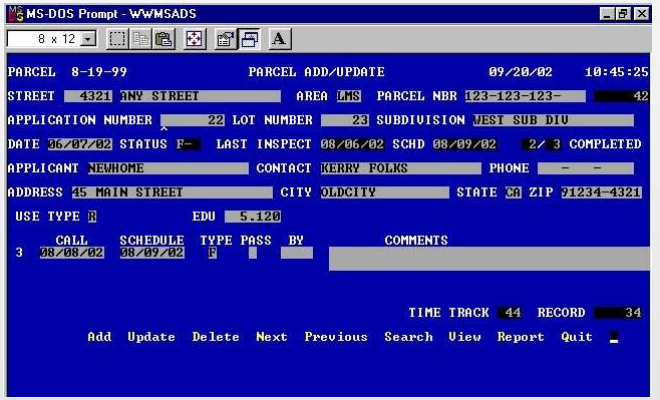

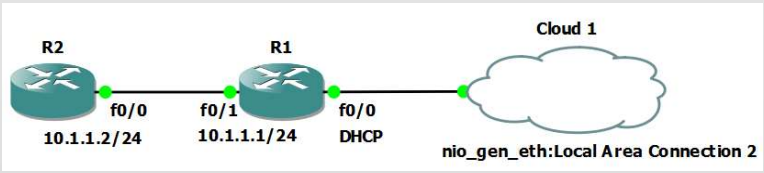

¿Por qué Virtualizar? (cont)

- Tengo que correr varios y distintos SO simultáneamente.
- Necesito hacer testeo y monitoreo de performance
- Necesito que SOs existentes se ejecuten en ambientes multiprocesadores que comparten memoria

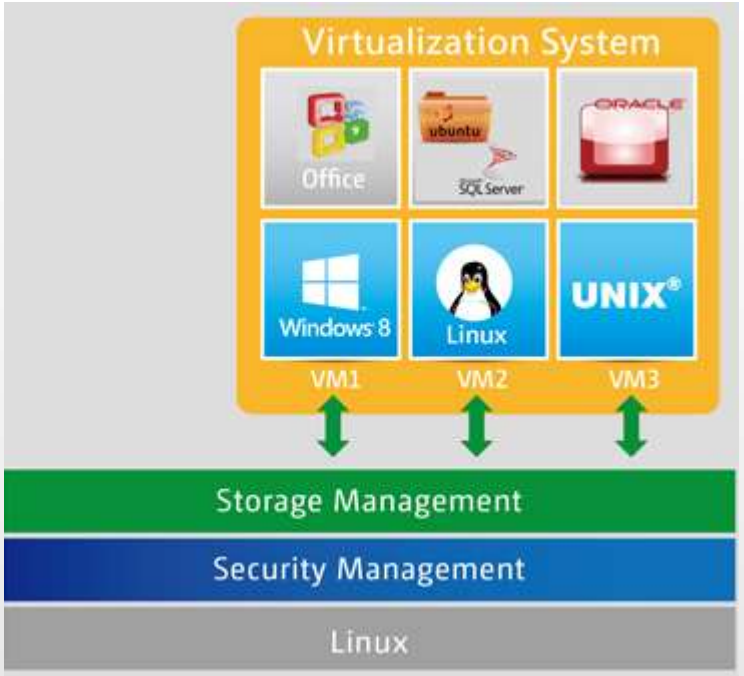

- Necesito facilidad de migración.
- Necesito ahorrar energía (tendencias de green IT, o tecnología verde)

Virtualización. Ideas generales

- Es una capa de abstracción sobre el hw, para obtener una mejor utilización de los recursos y flexibilidad.
- Permite que haya múltiples máquinas virtuales (MV) o entornos virtuales (EV), con distintos (o iguales) sistemas operativos corriendo aisladamente.
- Cada MV tiene su propio conjunto de hardware virtual (RAM, CPU, NIC, etc.) sobre el cual se carga el SO “guest”.
- El SO “guest” ve un conjunto consistente de hw, no el hw real (aunque a traves de ciertas configuraciones podría ver parte del hardware real)

Virtualización

- VM están representadas y son encapsuladas en archivos dentro de un File System.
- Fácil de almacenar, copiar.
- Sistemas completos (aplicaciones ya configuradas, so, hw virtual) pueden moverse de un servidor a otro, rapidamente.

Componentes: software host y guest

- Existe un software *host* (que simula) y un software *guest* (lo que se quiere simular).
- Guest puede ser un sistema operativo completo

Características de una MV

(Popek y Goldberg, 1974)

"Formal Requirements for Virtualizable Third Generation Architectures"

- **Equivalencia / Fidelidad:** un programa ejecutándose sobre un VMM (Virtual Machine Monitor) debería que tener un comportamiento idéntico al que tendría ejecutándose directamente sobre el hardware subyacente.
- **Control de recursos / Seguridad:** El VMM tiene que controlar completamente y en todo momento el conjunto de recursos virtualizados que proporciona a cada guest.
- **Eficiencia / Performance:** Una fracción estadísticamente dominante de instrucciones tienen que ser ejecutadas sin la intervención del VMM, o en otras palabras, directamente por el hardware.

http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.141.4815&rep=rep1&type=pdf

Emulación y virtualización

- Algunas maquinas virtuales en realidad son emuladas.
- Son técnicas parecidas, pero tienen diferencias
- **Emulación:** provee toda la funcionalidad del procesador deseado a través de software (ej: QUEMU, MAME).
  - Se puede emular un procesador sobre otro tipo de procesador
  - Tiende a ser lenta.
- **Virtualización:** se trata de particionar un procesador físico en distintos contextos, donde cada uno de ellos corre sobre el mismo procesador.
  - Es más rápida que la emulación.

Repasemos algunos conceptos ya vistos….

Interrupciones

- Evento que altera la secuencia de instrucciones ejecutada por un procesador
- Interrumpen el secuenciamiento del procesador durante la ejecucion de un proceso, llamándose al manejador de la interrupción
  - **Interrupciones enmascarables**: son ignoradas por la unidad de control por el tiempo que permanezca en ese estado.
  - **Interrupción no enmascarables**: siempre serán recibidas y atendidas por la CPU. Sólo unos pocos eventos críticos (como fallos del hardware) pueden generar interrupciones no enmascarables.

Excepciones

- Causadas por errores de programación o condiciones anómalas que deben ser manejadas por el kernel
- Algunas son detectadas por el procesador y otras son programadas
- Entre los tipos de excepción están los traps (los otros son fallos o abortos)

Modo usuario y supervisor

- En modo supervisor se puede ejecutar cualquiera de las instrucciones que acepta el procesador
- En modo usuario, no

Modo usuario/supervisor
Instrucciones privilegiadas

- Cuando estoy virtualizando, el guest (corriendo en modo usuario) emitirá una instrucción privilegiada que NO debe ser ignorada.
- INTEL 386 ignoraba las instrucciones privilegiadas que se invocaban en modo usuario.

Instrucciones privilegiadas y sensibles

- Para construir un VMM es suficiente con que todas las instrucciones que podrían afectar al correcto funcionamiento del VMM (instrucciones sensibles) siempre generen una excepción y pasen el control al VMM.
- Las instrucciones no privilegiadas deben ejecutarse nativamente (es decir, eficientemente).
- Una arquitectura es virtualizable si todas las instrucciones sensibles son privilegiadas.

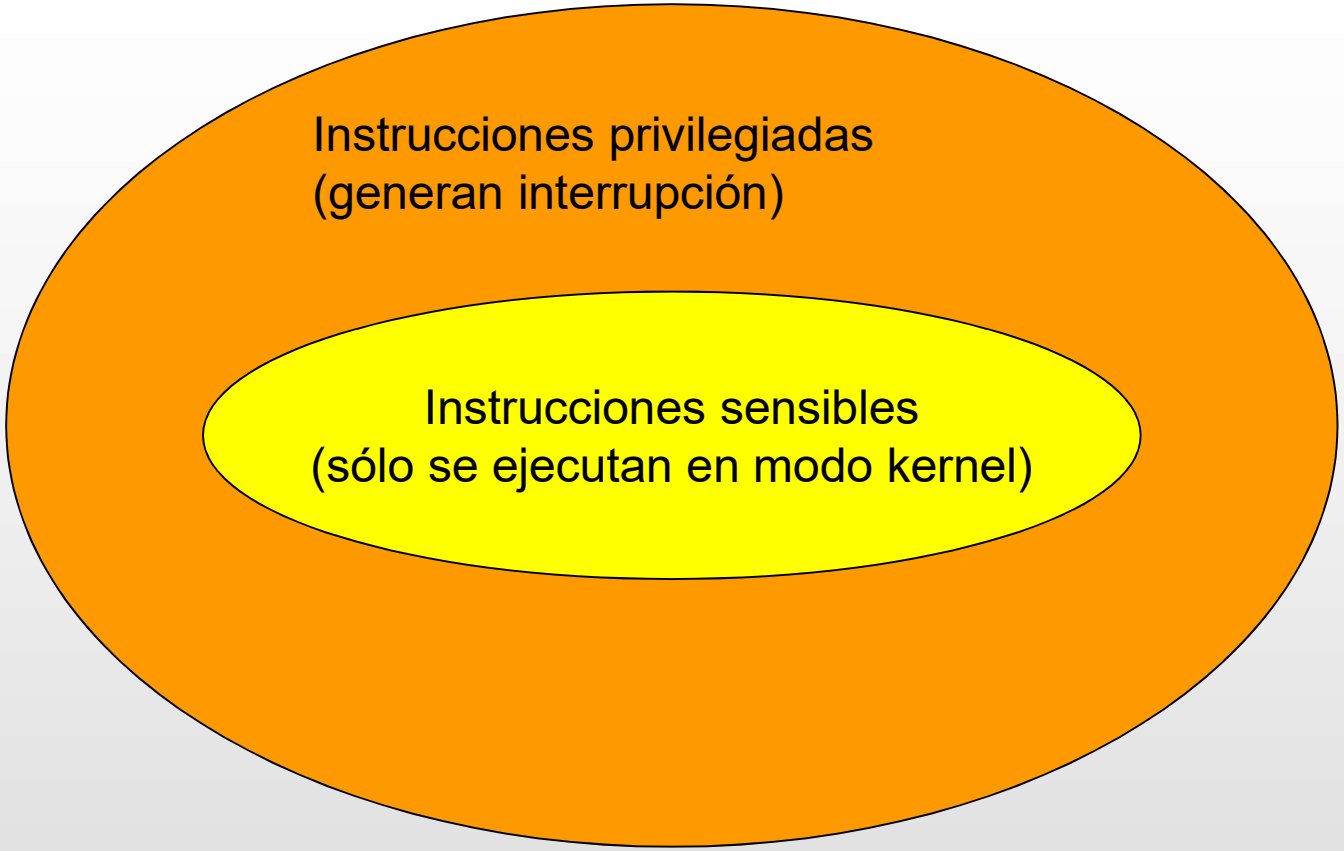
Instrucciones privilegiadas
(generan interrupción)
Instrucciones sensibles
(sólo se ejecutan en modo kernel)
Modo usuario
Modo supervisor

Anillos de privilegios en x86

- Los procesadores x86 proveen protección basada en el concepto de niveles o anillos (rings) de privilegios (0 = mas privilegio, 3 menos privilegio). Estos niveles se establecen en 2 bits del registro **CS**.
  - El software mas privilegiado se ejecuta en el Ring 0 (modo Kernel) y el menos privilegiado (modo usuario) en el 1, 2 o 3 (en particular en Intel se ejecuta en el 3)
- El nivel de privilegios determina si las instrucciones privilegiadas, que controlan la funcionalidad básica de la CPU, pueden ejecutarse sin generar una excepción
  - En Ring 0 se ejecutan directamente
  - En otros Rings se invocan a través de una excepción

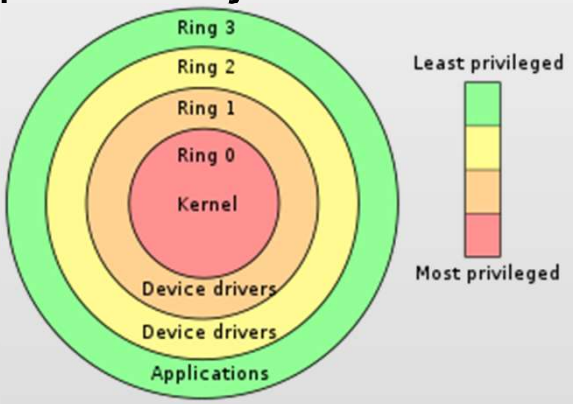

- Se busca que los Hypervisores se ejecuten en el Ring 0 (o lo mas cercano) y los SO guest se ejecuten en el 1 o 3 (x86)

Hypervisors

- También conocidos como VMM (Virtual Machine Monitor) es una porción de software que separa las “aplicaciones/SO” del hardware subyacente
- Proveen una plataforma de virtualización que permite múltiples SO corriendo en un host al mismo tiempo.

Hypervisors

- Interactúan con el HW en líneas generales (2° y 3° generación)
- Realizan la multiprogramación
- Ofrece varias MV hacia arriba

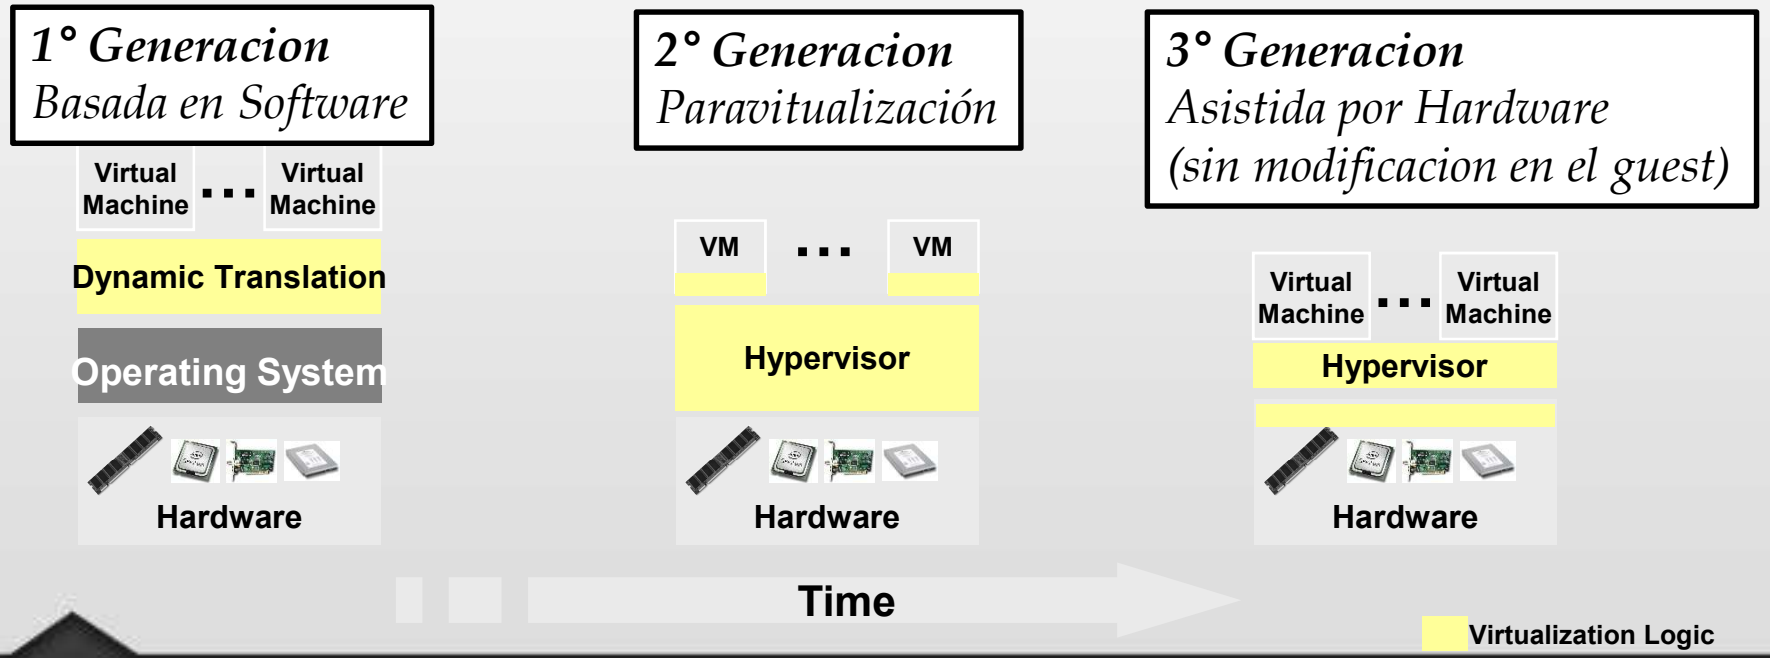

CPUs “virtualizables”

- El principal problema es la ejecución de excepciones/interrupciones desde los guest, ya que deben ser “controladas”. El hypervisor es quien realiza esta tarea
- Se necesitan CPU “virtualizables” (aptas para virtualizar)
- Intel la llama VT (Tecnología de virtualización)
- AMD la llama SVM (máquina virtual segura)
- Se usa VT en forma genérica

Hypervisor 1 e Hypervisor 2

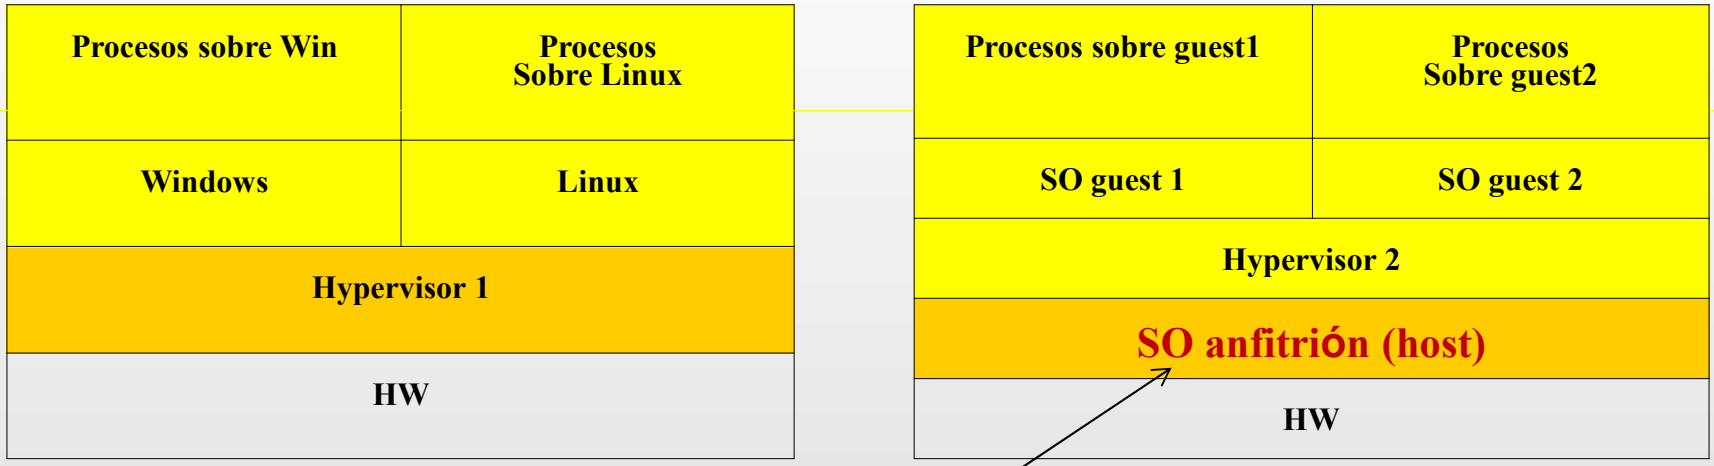

La diferencia mas importante es la existencia o no de un SO host

Hypervisor tipo 1

- Se ejecuta en modo kernel (Ring 0)
- Cada VM se ejecuta como un proceso de usuario en modo usuario (Ring 3)
- El SO host no requiere ser modificado
- Existen un modo kernel virtual y modo usuario virtual
- Siempre que la VM ejecuta una instrucción sensible, se produce una trap que procesa el hypervisor. Algunos hipervisores introducen extensiones que le evitan tener que traducir todas las instrucciones
- Debe tener asistencia de Hardware Siempre

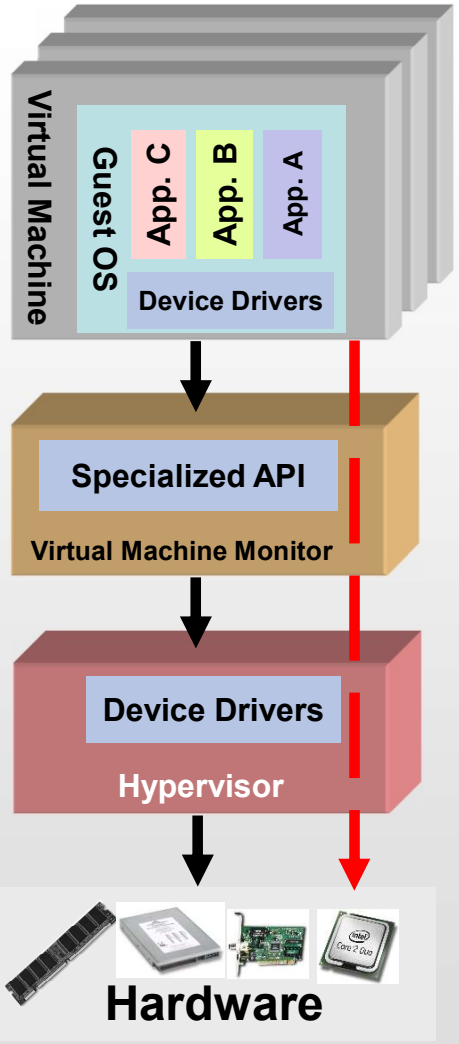

Hypervisor tipo 1

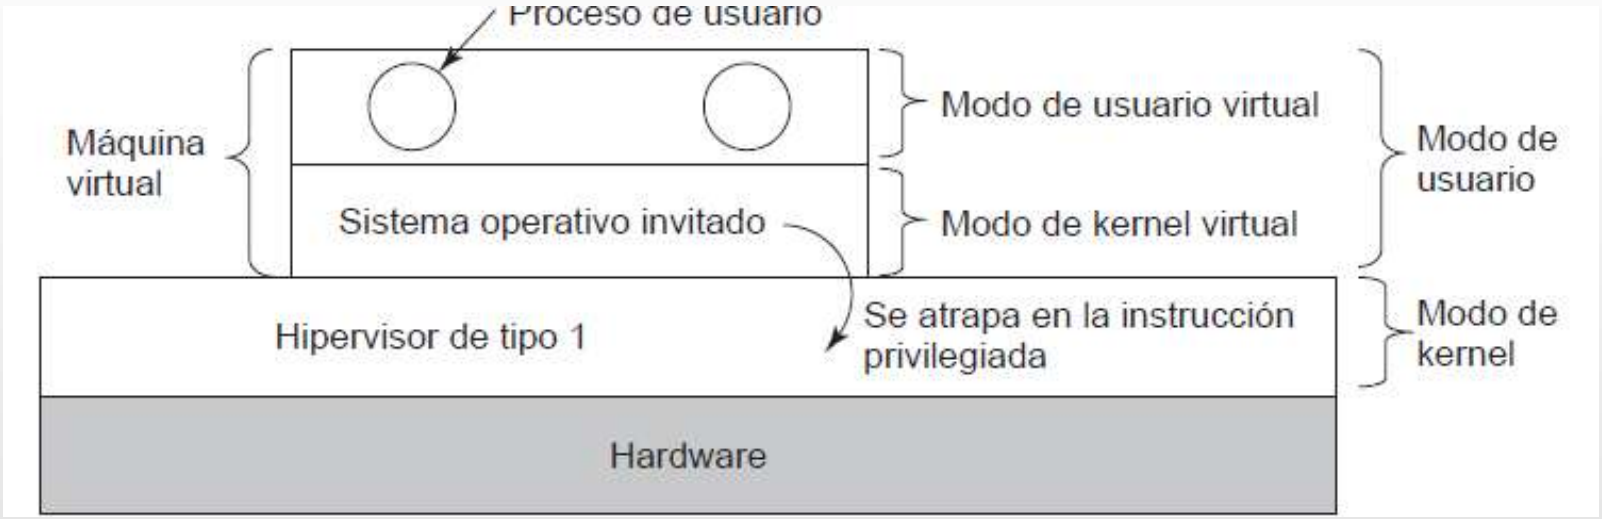

Hypervisor tipo 2

- Se ejecuta como un programa de usuario en un SO host
- Su función principal de interpretar un subconjunto de las instrucciones de hardware de la máquina sobre la que corre
- Debe emularse el hardware que se mapea a los SO guest

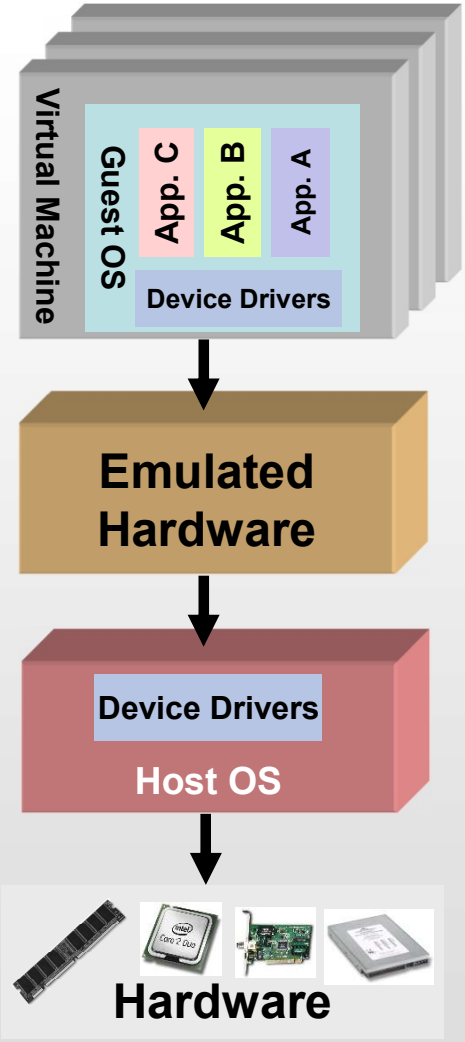

Hypervisors - Comparación

- **Tipo 1**
- Se ejecuta sobre el HW
- Hypervisor se ejecuta en modo kernel real
- SO guest es en modo kernel “virtual” (pero es modo usuario)

- **Tipo 2**
- Se ejecuta como un programa de usuario sobre un SO host.
- Arriba de él, están los SO guests.
- Interpreta un conjunto de instrucciones de máquina.
- El SO host es quién se ejecuta sobre el HW

Hypervisors - Comparación

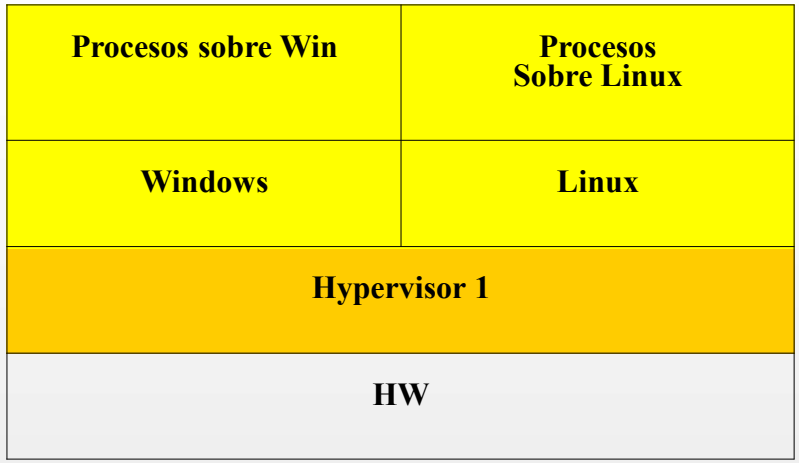

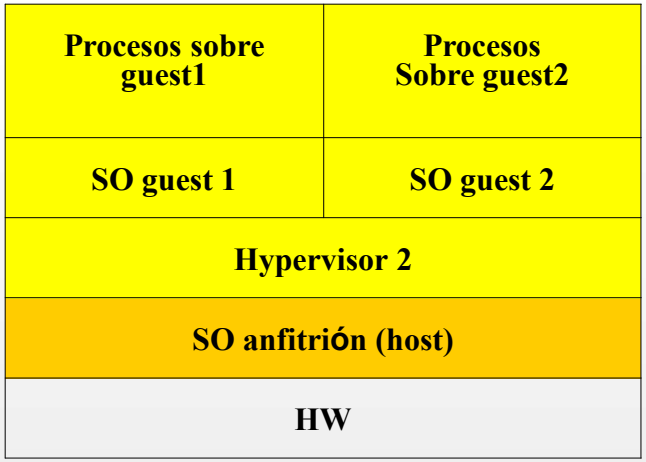

- Cuando un SO guest emite una instrucción sensible:
  - CPU no VT => ignora
  - CPU con VT =>hay un trap al kernel
  - Kernel analiza: si la emitió el proceso usuario, emulará el HW sobre el guest.

Se ejecuta como un programa de usuario sobre un SO host.
Arriba de él, están los SO guests

¿Por qué un hypervisor 2 funciona en CPU no VT?

- El hipervisor de tipo 2 ejecuta en modo usuario como un proceso más del SO anfitrión
- Las instrucciones sensibles se sustituyen por llamadas a procedimiento que emulan las instrucciones
- El verdadero HW NUNCA ejecuta las sensibles que emite el guest: las ejecuta como llamadas el hypervisor
- Todo el hardware es emulado, inclusive la CPU

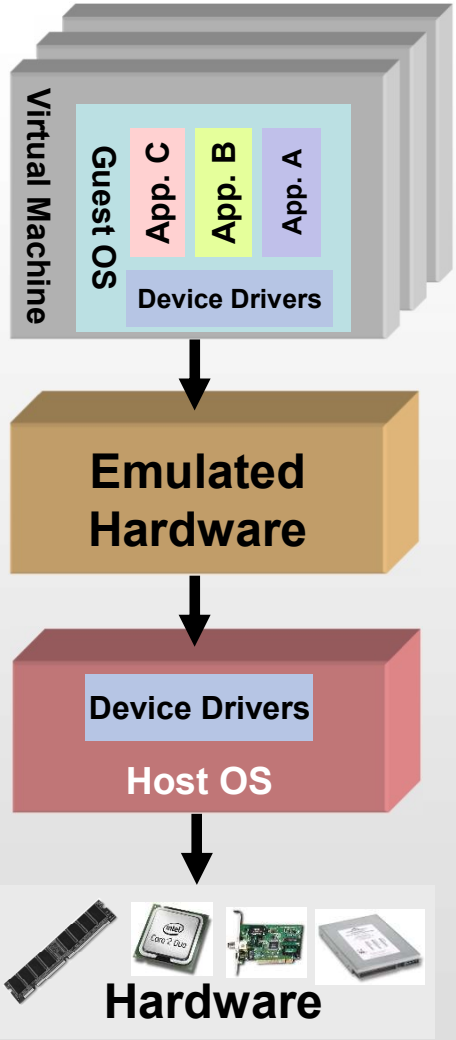

bochs think inside the bochs.

QEMU open source processor emulator

Traducción binaria

- El hypervisor continuamente analiza en runtime el flujo de ejecución (bloques de código) de los SO guest y “traduce” las instrucciones sensibles por llamadas al hipervisor
- EL VMM modifica en runtime la imágen binaria del SO guest con el fin de poder tener control sobre el guest cuando este intenta ejecutar una instrucción sensible
- Cuando se produce una instruccion sensible la intercepta, la convierte en una llamada al host y luego devuelve el control al guest.
- Los bloques traducidos son ejecutados por la CPU directamente

VMware Workstation

- Explora código buscando bloques básicos (instrucciones seguidas que no cambien el program counter).
- Si hay instrucciones sensibles, sustituye cada una por una llamada a VMware.
- El bloque se pone en la cache de VMware. Luego se ejecuta
- Si no hay instrucciones sensibles, el bloque se ejecuta tan rápido como si fuera nativa.

VMware Workstation

- La acción de atrapar instrucciones sensibles y emularlas se conoce como traducción automática.
- Generalmente tienen un costo en la performance:
  - -2% sobre CPU y RAM
  - Entre -8% y -20% para dispositivos de I/O

Performance – Tipo 1 vs Tipo 2

- Tipo 1: todas las instrucciones sensibles generan una trap que debe atender el hipervisor (arruina "localidad", caché de CPU, TLBs, predicción de bifurcación, etc desde el guest). El hypervisor maneja estos conceptos.
- Tipo 2: todo el flujo de instrucciones debe ser traducido (costo inicial alto) pero luego quedan en cache y no se produce cambio de contexto al ejecutar una instrucción sensible
  - Hipervisores de tipo 1 también pueden realizar traducción binaria

Resumen - Virtualización

- Es una capa de abstracción sobre el hw, para obtener una mejor utilización de los recursos y flexibilidad.
- Permite que haya múltiples máquinas virtuales (MV) o entornos virtuales (EV), con distintos (o iguales) sistemas operativos corriendo aisladamente.
- Cada MV tiene su propio conjunto de hardware virtual (RAM, CPU, NIC, etc.) sobre el cual se carga el SO "guest".
- El SO "guest" ve un conjunto consistente de hw, no el hw real (aunque a traves de ciertas configuraciones podría ver parte del hardware real)
- Existe un software *host* (que simula) y un software *guest* (lo que se quiere simular).

Resumen - Virtualización

- **Ventajas:**
  - Backup (las VM son archivos), independencia del hardware, asignación de recursos, mayor velocidad de despliegue
  - Mayor aprovechamiento de recursos, ahorro de energía
  - Otras…
- **Desventajas:**
  - Degradación de performance mínima

Resumen - Virtualización

- **Técnicas:**
  - **Emulación**: Provee toda la funcionalidad del procesador deseado a través de software (ej: QUEMU, MAME).
    - Se puede emular un procesador sobre otro tipo de procesador
    - Tiende a ser lenta.
  - **Virtualización**: Se trata de particionar un procesador físico en distintos contextos, donde cada uno de ellos corre sobre el mismo procesador.
    - Es más rápida que la emulación.

Resumen - Virtualización

- **Tipos de Virtualización:**

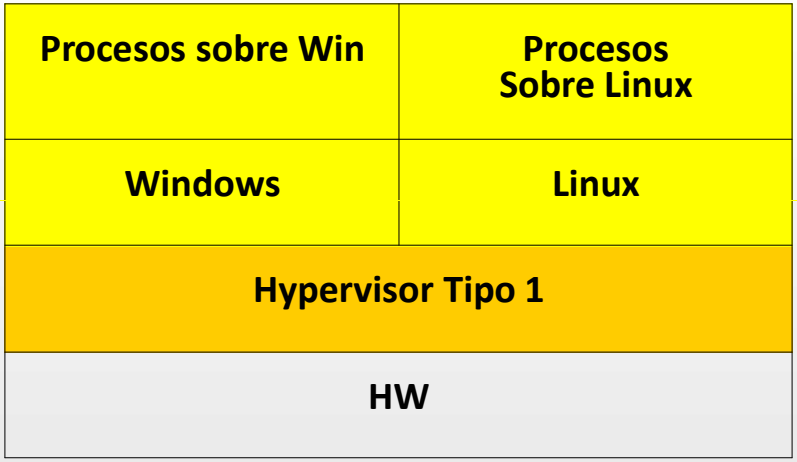

- Se ejecutan sobre el HW
- Se ejecuta en modo kernel real
- SO guest se ejecuta en modo kernel “virtual” (pero en realidad es modo usuario)

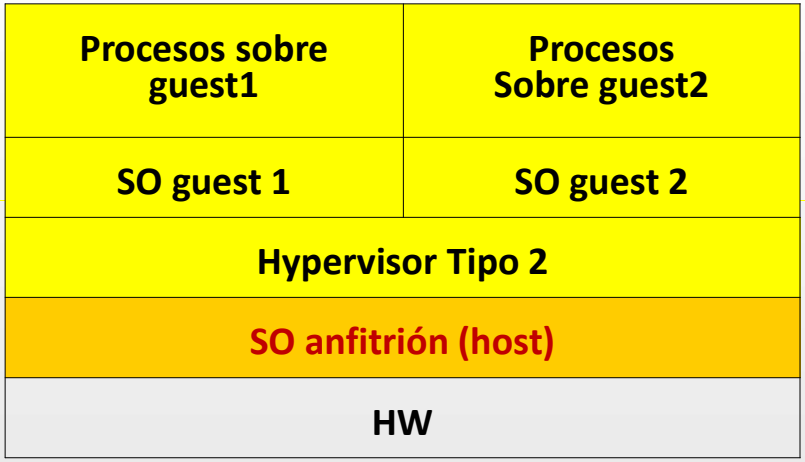

- Se ejecuta como un programa de usuario sobre un SO host.
- Arriba de él, están los SO guests.
- Interpreta un conjunto de instrucciones de máquina.
- El SO host es quién se ejecuta sobre el HW

Resumen - Virtualización

- **El desafío:**
  - Lograr que las instrucciones **no sensibles** sean ejecutadas directamente en el hardware
  - Las instrucciones sensibles deben ser atrapadas por el hypervisor y tratadas de un modo especial (traducción binaria)
  - Se busca que la performance sea máxima
  - Los SO Guest deben ejecutarse del mismo modo que lo harían en modo bare metal, sin requerir modificaciones sobre los mismos.

Paravirtualización

- Los Hypervisores tipo 1 y 2 ejecutan SO guest no modificados.
- Paravirtualización: se trata de tener SO guests modificados, para mejorar el rendimiento.
- Cuando se quiere ejecutar una instrucción sensible, el SO guest la transforma en una llamada al VMM que expone una API específica.
- El VMM:
  - No realiza traducción binaria completa
  - No debe emular instrucciones de hardware, lo cual hace que las llamadas se resuelvan de modo mas sencillo
- El SO guest es como un proceso de usuario que hace llamadas al SO (el hypervisor)

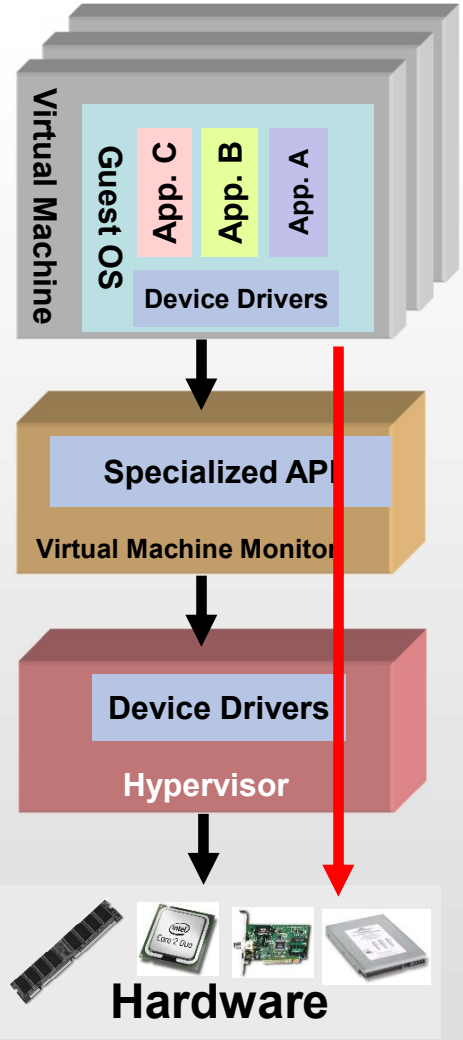

Paravirtualización - Como se implementa

- El hypervisor cuenta con una API, que son un conjunto de llamadas a procedimientos.
- Los guests, en vez de invocar instrucciones sensibles, invocan a estas llamadas.
- Se eliminan las instrucciones sensibles de los guest y se reemplazan por llamadas a la API especializada.
- El hypervisor se transforma en un microkernel.
- Decimos que un SO está paravirtualizado cuando se han eliminado, intencionalmente, algunas instrucciones sensibles (si se eliminan todas es paravirtualización completa si solo se eliminan algunas, se la llama paravirtualización parcial)
- Si no se eliminan TODAS las instrucciones sensibles, el VMM deberá realizar traducción binaria

Paravirtualización - Implementaciones

- Existen 2 modelos:
  - **Recompilando el Kernel del sistema guest:**
    - Los drivers y la forma de invocar a la API residen en el kernel
    - Es necesario instalar un sistema operativo modificado/específico
  - **Instalando drivers paravirtualizados:**
    - La paravirtualización es parcial (para algunas funciones y dispositivos)
    - Generalmente utilizada para placas de red, o gráficas
    - **Esta es la técnica que se utiliza hoy en día**

Virtualización vs. Paravirtualización

<table>
<tr><th>virtualización “completa”</th><th>paravirtualización</th></tr>
<tr><td colspan="2">Procesos usuario</td><td colspan="2">Procesos usuario</td></tr>
<tr><td>SO sin modificar (GNU/Linux, Windows)</td><td>Trap x instrucciones sensibles.
Hypervisor emula y regresa.</td><td>Se accede a la API para todas o ciertas instrucciones.
Se desacopla la función del hypervisor y VMM</td><td>SO modificado (GNU/Linux, Windows)</td></tr>
<tr><td colspan="2">Hypervisor tipo 1</td><td colspan="2">Microkernel</td></tr>
<tr><td colspan="4">HARDWARE</td></tr>
</table>

Virtualización vs. Paravirtualización

- Virtualización completa o nativa puede generar problemas de performance ya que tiene que **emular la totalidad del hardware**.
- Paravirtualización completa en Kernel tiene mejor performance, pero soporta pocos SO, pues necesita modificar el SO original.
- Paravirtualización parcial en drivers podría ser una solución intermedia

KVM (Kernel-based Virtual Machine)

- Infraestructura de virtualización para el kernel de Linux.
- Soportado nativamente en el Kernel desde 2.6.20
- Se lo considera tipo 1, ya que está embebida en el Kernel del SO
- Virtualiza plataformas X86 de 32 y 64 bits
- Requiere un procesador con extensión para virtualización.
- Sistemas Operativos guest que admite: versions de Linux, BSD, Solaris, Windows, Haiku, ReactOS, Plan 9, AROS Research Operating System, Android 2.2, GNU/Hurd (Debian K16), Minix 3.1.2a, Solaris 10 U3, Darwin 8.0.1, entre otros
- Soporta paravirtualización de algunos dispositivos para Linux, OpenBSD, FreeBSD, NetBSD, Plan 9 y Windows mediante API

https://www.redhat.com/es/topics/virtualization/what-is-KVM

ProxmoxVE

- No es en si un Hipervisor, sino que es una distribución GNU/Linux basad en Debian que agrupa funcionalidades de virtualización:
  - Utiliza KVM como Hipervisor y LXC para la gestión de contenedores. También utiliza QEMU para emular ciertas VMs
  - Provee una interfaz web y una CLI para la gestión de las VMs
  - Es de código abierto
  - Ya que usa KVM, aprovecha sus características como por ejemplo la migración en caliente
  - Soporta CEPH, que permite crear un Sistema de archivos distribuido entre todos los hosts
  - Se puede configurar en cluster (varios hosts corriendo proxmox y gestionarlos desde uno de ellos)
  - Su instalación es sencilla a través de una ".ISO". El instaldor prove el SO y las herramientas.

ProxmoxVE

Facultad de Informática
UNIVERSIDAD NACIONAL DE LA PLATA

Hyper-V (Windows Server Virtualization)

- Infraestructura de virtualización propietaria de Microsoft
- Requiere un procesador con extensión para virtualización.
- Virtualiza plataformas X86 de 32 y 64 bits
- Se lo considera tipo 1, ya que está embebida en el Kernel del SO
- También conocido como Viridian fué introducido en Windows 2008 server en el año 2008
- Es un hypervisor native. La funcionalidad se agrega como un Nuevo “Rol” en versions de Windows Server y Windows 10 Pro (no Home Edition)
- Permite correr SO guest Windows, GNU/Linux, BSD y otros
- Junto con VMWare lideran el Mercado de los sistemas de virtualización empresariales

VMware

- Infraestructura de virtualización propietaria
- Porvee 2 versiones:
  - Workstation: Es un hypervisor tipo 2 y requiere un procesador con extensión para virtualización
  - ESXi o vSphere para servers: Es un hypervisor tipo 1
- Virtualiza plataformas X86 de 32 y 64 bits
- Virtualiza redes, firewalls, almacenamiento
- Incluye una importante suite de herramientas que permiten, de acuerdo a la licencia adquirida, utilizar un mayor o menos número de funciones
- ESXi, junto con Hyper-V lideran el Mercado de los sistemas de virtualización empresariales

Xen

- Infraestructura de virtualización de código abierto desarrollada por la Universidad de Cambridge
- Requiere un procesador con extensión para virtualización.
- Virtualiza plataformas X86 de 32 y 64 bits
- Es un hypervisor nativo y también soporta paravirtualización
- Permite correr SO guest Windows, GNU/Linux, BSD y otros
- Permite la migración de máquinas virtuales en caliente entre miembros de un cluster XEN

https://xenproject.org/

Linux Containers

- Grupos de procesos corriendo sobre el mismo kernel pueden aislarse en entornos que parecen máquinas separadas.

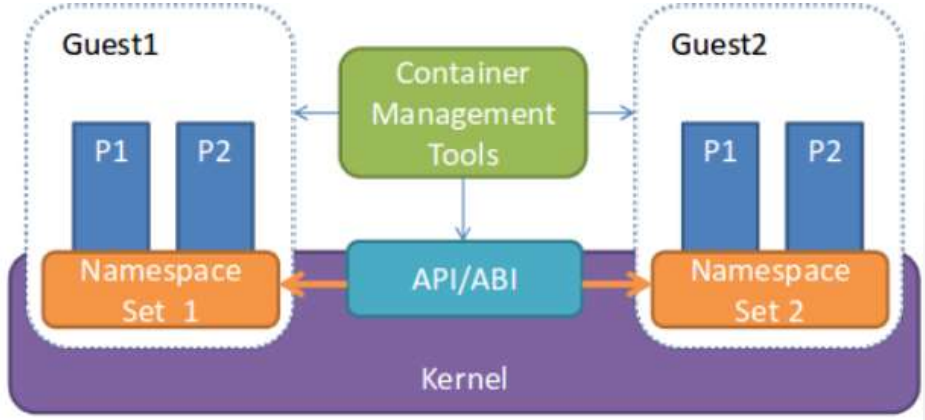

- No son una máquina virtual
- Son entornos virtuales, con su propio espacio de procesos y de nombres
- Se basan en cgroups (funcionalidad propia del kernel Linux)
- Algunos le llaman “virtualización por sistema operativo”

Linux Containers

- Algunos usos:
- Controlar asignación de recursos. Puedo asignarle a un container más ancho de banda de red, o tiempo de CPU
- Se puede “freezar” un container (todos los procesos del container se suspenden. Util para migraciones.

Máquinas virtuales vs containers

MV

- Existe una instancia del kernel
- Puedo disponer de distintos sistemas operativos
- Mayor Consumo de recursos por cada máquina virtual
- Ofrecen mayor separación y seguridad.

Containers

- No es necesario
- La virtualización se puede hacer por SO y por aplicación
- La creación y destrucción de contenedores es menos costosa

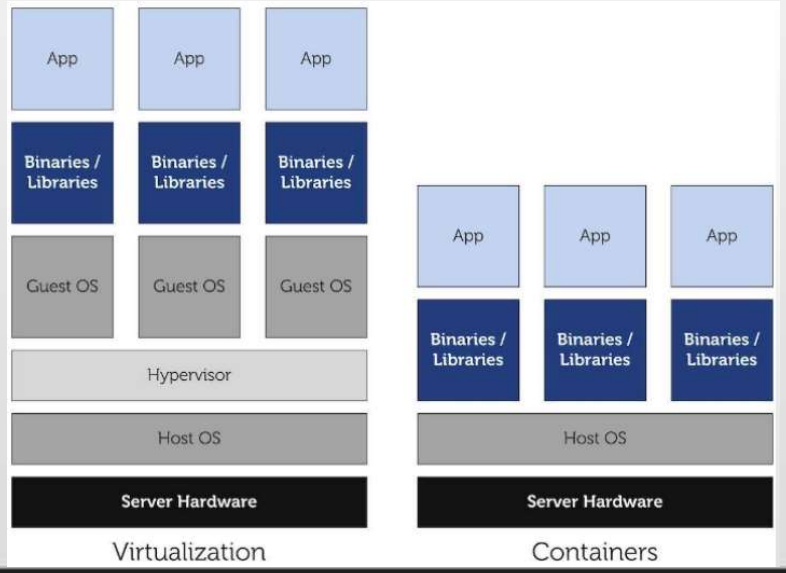

Resumiendo…

Emulación

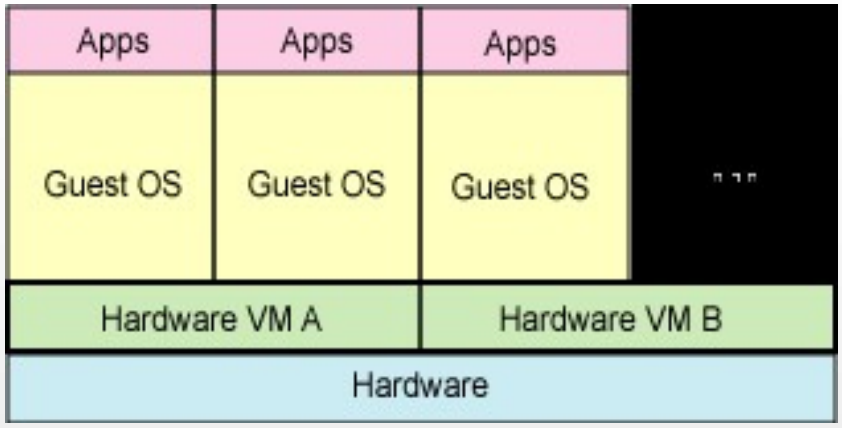

V. completa

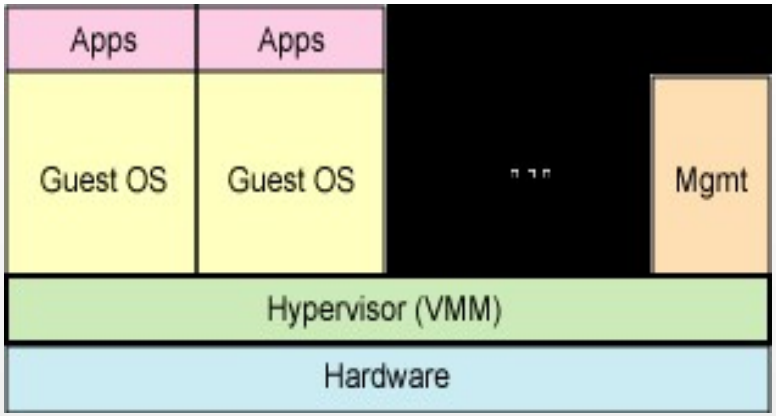

Paravirtualización

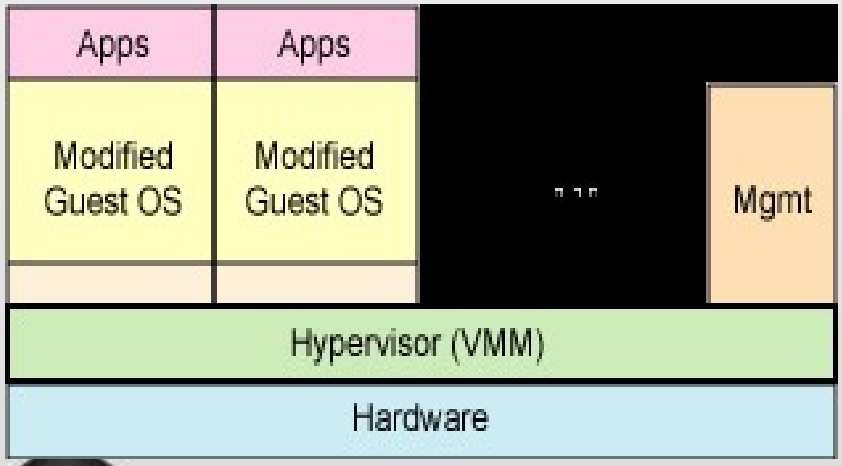

A nivel de SO